

# BÁO CÁO ĐÁNH GIÁ PILOT S2G-RAG

Hiệu quả retrieval, độ bao phủ evidence, chất lượng câu trả lời, độ trễ, chi phí và quy trình đánh giá có thể tái lập

## KẾT QUẢ TẠM THỜI - PILOT CÓ HỖ TRỢ CỦA AGENT

Chưa phải benchmark khóa luận đã đóng băng cho đến khi hoàn tất kiểm chứng độc lập bởi con người.

|              |                                                             |
|--------------|-------------------------------------------------------------|
| Corpus       | Canonical Corpus V1.1 - 27 PDF - 3.482 chunk                |
| Pilot        | 20 câu hỏi - 27 nhóm evidence - 23 GT chunk duy nhất        |
| Thực thi     | Hoàn thành 20/20 - 94 provider calls tính cả lần retry P004 |
| Ngày báo cáo | 2026-09-13                                                  |

# Phần I - Kết quả đánh giá pilot

Kết quả quan sát từ pilot kỹ thuật gồm 20 câu hỏi. Toàn bộ cảnh báo và giới hạn về tính hợp lệ được giữ nguyên.

## Kết luận chính

Pipeline hoàn thành kết quả hợp lệ cho 20/20 câu hỏi sau một lần chạy lại có kiểm soát ở P004. Kết quả cho thấy retrieval cơ sở đã khá tốt ở top-10, nhưng S2G hiện chưa tăng độ bao phủ tổng thể và còn làm mất evidence ở bước chọn/trích dẫn, đặc biệt với câu hỏi multi-evidence. Phần sinh trả lời đúng 14/20 và đầy đủ 13/20 theo đánh giá thủ công có hỗ trợ của agent; chỉ 11/20 câu đạt đồng thời bốn tiêu chí cốt lõi. Đây là kết quả pilot chẩn đoán, chưa phải đánh giá độc lập bởi con người.

## Phạm vi và tính hợp lệ

- Corpus: Canonical Corpus V1.1, 27 tài liệu, 3.482 chunk.
- Pilot: 20 câu hỏi, 27 evidence groups, 23 GT chunks duy nhất.
- Trạng thái benchmark: DRAFT\_AGENT\_VERIFIED\_PENDING\_HUMAN.
- Runtime không nhận ground truth; evaluator offline chỉ mở GT sau khi kết quả đã đóng.
- Cấu hình retrieval/controller không được thay đổi trong lần chạy này.
- Kết quả mới được lưu riêng dưới outputs/evaluation/s2g\_pilot\_rerun\_20260913/; kết quả pilot cũ không bị ghi đè.

## Chất lượng truy xuất

### B0 — Hybrid + RRF + reranker

| Chỉ số                     | Kết quả |
|----------------------------|---------|
| Recall@1                   | 0,575   |
| Recall@3                   | 0,825   |
| Recall@5                   | 0,825   |
| Recall@10                  | 0,825   |
| MRR@10                     | 0,767   |
| Evidence-group coverage@10 | 0,825   |
| Complete-evidence@10       | 15/20   |

BM25 riêng lẻ đạt Recall/EGC@10 = 0,875 và complete-evidence@10 = 16/20, cao hơn đầu ra sau reranker ở top-10. Reranker tăng kết quả sớm ở @1 nhưng đẩy một số evidence đúng khỏi top-10. Đây là dấu hiệu cần kiểm tra ranking loss theo từng câu, không phải cơ sở để tinh chỉnh trực tiếp trên chính 20 câu pilot.

### S2G theo từng giai đoạn

| Giai đoạn                | Recall@1 | Recall@10 | MRR@10 | EGC@10 | Complete @10 |
|--------------------------|----------|-----------|--------|--------|--------------|
| Iterative candidate pool | 0,500    | 0,825     | 0,714  | 0,825  | 15/20        |
| S2G selected evidence    | 0,650    | 0,800     | 0,850  | 0,800  | 14/20        |
| Answer citations         | 0,600    | 0,800     | 0,817  | 0,800  | 14/20        |

Selector làm evidence đúng xuất hiện sớm hơn, thể hiện qua  $MRR@10$  tăng, nhưng làm giảm bao phủ từ 0,825 xuống 0,800 và giảm số câu đủ evidence từ 15 xuống 14. Vì vậy hệ thống hiện thiên về độ chính xác sớm hơn là giữ đủ evidence.

### Theo loại câu hỏi quan trọng

| Loại                     | Giai đoạn     | $MRR@10$ | $EGC@10$ | Complete @10 |
|--------------------------|---------------|----------|----------|--------------|
| Multi-evidence (4)       | B0 reranker   | 0,625    | 0,625    | 2/4          |
| Multi-evidence (4)       | S2G citations | 0,750    | 0,500    | 1/4          |
| Cross-document (3)       | B0 reranker   | 0,667    | 0,667    | 1/3          |
| Cross-document (3)       | S2G citations | 1,000    | 0,667    | 1/3          |
| Direct lookup (5)        | S2G citations | 1,000    | 1,000    | 5/5          |
| Terminology mismatch (3) | S2G citations | 1,000    | 1,000    | 3/3          |

Điểm yếu rõ nhất là multi-evidence: evidence đầu tiên thường được tìm sớm nhưng evidence bắt buộc thứ hai bị thiếu. Cross-document cũng chỉ đủ hoàn toàn 1/3 câu, dù evidence đầu tiên có thứ hạng tốt.

### Chất lượng thành phần sinh

Đánh giá được thực hiện bằng cách đối chiếu từng câu trả lời với câu hỏi, GT chunk và source\_text. Đây là đánh giá thủ công **có hỗ trợ của agent**, không phải nghiên cứu annotation độc lập bởi người đánh giá.

| Tiêu chí                     | PASS | FAIL | REVIEW | PASS trên 20 câu |
|------------------------------|------|------|--------|------------------|
| Đúng đắn                     | 14   | 5    | 1      | 70%              |
| Đầy đủ                       | 13   | 6    | 1      | 65%              |
| Trung thành với evidence     | 18   | 2    | 0      | 90%              |
| Citation đầy đủ về ngữ nghĩa | 13   | 6    | 1      | 65%              |
| Rõ ràng                      | 18   | 2    | 0      | 90%              |

- 11/20 câu đạt đồng thời bốn tiêu chí cốt lõi: đúng, đủ, trung thành và citation đầy đủ.
- Hợp đồng citation tự động đạt 20/20: có citation khi trả lời và mọi citation đều thuộc final evidence. Tuy nhiên citation đầy đủ về **ngữ nghĩa** chỉ đạt 13/20; điều này chứng minh kiểm tra schema không thay thế đánh giá nội dung.
- Hai câu trả lời tự khai báo *insufficient*: P015 và P016. Cả hai thực tế đều có GT, nên đây là thất bại tìm/chọn đủ evidence chứ không phải câu hỏi không trả lời được.
- Các trường hợp cần chú ý: P003 trộn ngữ cảnh thừa; P007 trả lời sai trọng tâm; P013 bỏ mờ điều kiện phải dự bài đánh giá; P014 thiếu danh sách chứng chỉ; P015, P016 và P019 thiếu một về evidence; P018 kết luận đúng nhưng citation không chứng minh đủ cả hai tài liệu; P017 cần người xác minh phạm vi của hai mốc thời gian.

### Độ trễ, token và chi phí

#### B0 cục bộ

| Thành phần | Trung bình | Trung vị | P95     | Lớn nhất |
|------------|------------|----------|---------|----------|
| BM25       | 0,017 s    | 0,011 s  | 0,025 s | 0,107 s  |
| Dense      | 0,127 s    | 0,057 s  | 0,175 s | 1,629 s  |
| Reranker   | 1,023 s    | 0,929 s  | 1,184 s | 2,873 s  |
| Tổng       | 1,168 s    | 0,993 s  | 1,361 s | 4,610 s  |

## S2G + GPT-5-nano

- 92 provider calls trong 20 artifact cuối.
- 137.455 input tokens; 1.280 cached input tokens; 66.988 output tokens, trong đó 48.064 reasoning tokens.
- Chi phí API ước tính của 20 artifact cuối: **0,033610 USD**.
- Trung bình 23,91 giây/câu; trung vị 18,53 giây; P95 47,39 giây; lớn nhất 55,20 giây.
- Trung bình 1,35 vòng retrieval/câu; tối đa 4 vòng.
- Stop reason: 17 STOP\_SUFFICIENT, 2 STOP\_NO\_NEW\_EVIDENCE, 1 STOP\_MAX\_TURNS.

P004 ở lần đầu phát sinh `Duplicate evidence ID` tại `sentence selector`. Lần thất bại này dùng thêm 2 provider calls, 2.430 input tokens, 1.781 output tokens và chi phí ước tính 0,000834 USD. Tính cả lần thất bại, thực nghiệm dùng 94 calls và chi phí API ước tính **0,034444 USD**. P004 hoàn thành khi chạy lại từ đầu; lỗi đầu tiên được giữ trong audit, không được tính thành điểm retrieval bằng 0.

## Cơ sở cải tiến

Ưu tiên cải tiến được rút ra từ lỗi có quan sát, không phải tối ưu tham số trên pilot:

1. **Giữ đủ evidence cho câu nhiều vế.** Controller cần biểu diễn các yêu cầu con của câu hỏi và chỉ kết luận đủ khi mỗi yêu cầu có evidence độc lập. Không được dùng GT ở runtime.
2. **Giảm mất mát tại selector/citation.** Candidate pool đạt EGC@10 0,825 nhưng selected/citations chỉ còn 0,800. Cần trace rõ evidence nào bị loại và lý do, đồng thời bảo toàn evidence hỗ trợ các vế khác nhau.
3. **Thêm kiểm tra claim–citation.** Mỗi mệnh đề chính trong câu trả lời phải được gắn với evidence thực sự chứng minh mệnh đề đó; kiểm tra “citation thuộc final evidence” hiện chưa đủ.
4. **Cải thiện độ đầy đủ trước khi sinh.** P014–P016, P018–P019 cho thấy reasoner có thể trả lời trôi chảy từ một phần evidence nhưng bỏ vế còn lại.
5. **Làm bền giao diện sentence selector.** Evidence ID trùng nên được xử lý theo chính sách deterministic đã kiểm thử (ví dụ từ chối và retry có audit, hoặc canonical dedup nếu đặc tả cho phép), tránh làm hỏng toàn bộ request.
6. **Đánh giá trên tập giữ lại.** Sau khi sửa, cần dùng benchmark/holdout mới hoặc protocol pre-registered; không báo cáo cải thiện trên chính 20 câu đã dùng để chẩn đoán.

## Artifact

- `b0_rankings.json`, `b0_metrics.json`
- `s2g_rankings.json`, `s2g_retrieval_metrics.json`
- `s2g_resource_metrics.json`
- `answer_quality_review.csv` — các cột HUMAN vẫn để trống
- `answer_quality_agent_review.json`, `answer_quality_agent_summary.json`
- `s2g_runtime/runtime/P001` đến `P020` — trace và kết quả từng câu
- `s2g_runtime/runtime/P004/failure_attempt_1.json` — audit lỗi selector lần đầu
- `s2g_retry_p004/runtime/P004/` — trace đầy đủ của lần chạy lại thành công

Tất cả nằm dưới `outputs/evaluation/s2g_pilot_rerun_20260913/`.

# Phụ lục A - Quy trình đánh giá

Định nghĩa, ground-truth firewall, lệnh tái lập, yêu cầu kiểm tra của con người và giới hạn diễn giải.

## Phạm vi và trạng thái

Quy trình này đo lường sản phẩm full-PDF hiện tại theo năm khía cạnh:

1. recall của retrieval;
2. thứ hạng nghịch đảo trung bình (MRR);
3. độ bao phủ nhóm evidence (EGC);
4. chất lượng câu trả lời được con người đánh giá;
5. độ trễ end-to-end và chi phí OpenAI API.

data/evaluation/s2g\_pilot\_v1/queries.json là bộ pilot gồm 20 câu hỏi và 27 nhóm evidence dựa trên Canonical Corpus V1.1. Trạng thái hiện tại là DRAFT\_AGENT\_VERIFIED\_PENDING\_HUMAN. Các điểm số thô có thể dùng để chẩn đoán kỹ thuật nhưng không được mô tả là kết quả của một nghiên cứu annotation độc lập bởi con người. Báo cáo khóa luận chính thức yêu cầu hoàn tất ground\_truth\_review.csv và chỉ đổi trạng thái từng câu thành human\_verified sau khi kiểm tra.

## Ground-truth firewall

File benchmark chứa nhãn evidence. File runtime chỉ chứa đúng hai trường id và query; loader từ chối mọi trường bổ sung. Vì vậy, quá trình chạy retrieval và S2G không thể nhìn thấy ground truth. Offline evaluator chỉ đọc nhãn evidence sau khi bảng xếp hạng/kết quả đã được hoàn tất.

CLI mặc định yêu cầu trạng thái human\_verified. Cờ --allow-pending-human chỉ là lựa chọn tường minh để chạy phép đo kỹ thuật tạm thời.

## Chỉ số retrieval

- Recall@k: số chunk ID liên quan duy nhất xuất hiện trong k kết quả đầu, chia cho toàn bộ chunk ID liên quan duy nhất của câu hỏi.
- MRR@10: nghịch đảo thứ hạng của chunk liên quan đầu tiên trong 10 kết quả đầu; bằng 0 nếu không tìm thấy.
- Evidence-group Coverage@k: số nhóm evidence bắt buộc được bao phủ trong k kết quả đầu, chia cho tổng số nhóm bắt buộc. Một nhóm được bao phủ nếu xuất hiện ít nhất một chunk ID được chấp nhận của nhóm.
- Complete-evidence@k: chỉ đúng khi toàn bộ nhóm bắt buộc được bao phủ.

Các chỉ số được báo cáo theo từng câu hỏi, trung bình macro và theo query type. Với S2G, báo cáo tách riêng iterative candidate pool, các chunk do reranker trình bày, parent chunk được sentence selector chọn và citation của câu trả lời. Các giai đoạn này không thể dùng thay thế cho nhau.

## Chất lượng câu trả lời

Kiểm tra tự động chỉ bao phủ các hợp đồng có thể cưỡng chế: citation ID phải thuộc final evidence và câu trả lời có nội dung phải kèm citation. Chất lượng ngữ nghĩa được kiểm tra trong answer\_quality\_review.csv. Người đánh giá ghi TRUE/FALSE cho tính đúng đắn, đầy đủ, trung thành với evidence, mức đầy đủ của citation và độ rõ ràng, kèm ghi chú. Toàn bộ trường HUMAN để trống khi file được tạo. Báo cáo phải luôn có cả tử số/mẫu số và tỷ lệ phần trăm; không được âm thầm loại câu trả lời insufficient.

## Độ trễ và chi phí

Trace retrieval ghi độ trễ của BM25, dense, fusion, reranker và tổng thời gian. Trace S2G ghi độ trễ từng lần retrieval, độ trễ gọi provider và độ trễ end-to-end. Báo cáo sử dụng trung bình, trung vị, P95 và giá trị lớn nhất theo câu hỏi.

Chi phí token dùng usage do Responses API ghi nhận gồm input\_tokens, cached input token và output\_tokens. Cấu hình lưu ngày quan sát giá và nguồn giá. Ước tính này không bao gồm chi phí máy cục bộ, điện năng và mạng; do đó phải được gọi là chi phí API ước tính, không phải tổng chi phí hệ thống.

## Các lệnh tái lập

Sử dụng môi trường của dự án:

```
[bash]
conda run -n ml-env python -m src.evaluation.cli validate
conda run -n ml-env python -m src.evaluation.cli export-runtime \
  --output data/evaluation/s2g_pilot_v1/runtime_queries.json
conda run -n ml-env python -m src.evaluation.cli run-b0 \
  --runtime-queries data/evaluation/s2g_pilot_v1/runtime_queries.json \
  --output outputs/evaluation/s2g_pilot_v1/b0_rankings.json
conda run -n ml-env python -m src.evaluation.cli evaluate-b0 \
  --rankings outputs/evaluation/s2g_pilot_v1/b0_rankings.json \
  --output outputs/evaluation/s2g_pilot_v1/b0_metrics.json
conda run -n ml-env python -m src.evaluation.cli run-s2g \
  --runtime-queries data/evaluation/s2g_pilot_v1/runtime_queries.json \
  --output-root outputs/evaluation/s2g_pilot_v1/s2g_runtime
conda run -n ml-env python -m src.evaluation.cli evaluate-s2g \
  --runtime-root outputs/evaluation/s2g_pilot_v1/s2g_runtime \
  --output-root outputs/evaluation/s2g_pilot_v1
```

Cho đến khi hoàn tất kiểm chứng bởi con người, chỉ thêm --allow-pending-human vào các lệnh validate, export và offline evaluation. Lệnh thực thi chỉ đọc file runtime đã loại nhãn và không bao giờ tải benchmark.

## Giới hạn diễn giải

Hai mươi câu hỏi được phân tầng chỉ là pilot, không phải ước lượng toàn diện cho mọi câu hỏi có thể có của sinh viên. Việc soạn câu hỏi, kiểm tra ground truth, hành vi mô hình, nhiễu OCR và sự mơ hồ về vòng đời tài liệu là các nguy cơ độc lập đối với tính hợp lệ. Không được tinh chỉnh prompt, cấu hình retrieval hoặc câu hỏi sau khi xem kết quả từng câu trong pilot rồi báo cáo trên chính tập đó như một kết quả không thiên lệch.

---

Nguồn nội dung: docs/s2g-pilot-rerun-2026-09-13.md và docs/evaluation-protocol-vi.md. Số liệu lấy từ artifact chạy lại dưới outputs/evaluation/s2g\_pilot\_rerun\_20260913/.