

BÁO CÁO ĐÁNH GIÁ PILOT S2G-RAG

Hiệu quả retrieval, độ bao phủ evidence, chất lượng câu trả lời, độ trễ, chi phí và quy trình đánh giá có thể tái lập

KẾT QUẢ TẠM THỜI - PILOT CÓ HỖ TRỢ CỦA AGENT

Chưa phải benchmark khóa luận đã đóng băng cho đến khi hoàn tất kiểm chứng độc lập bởi con người.

Corpus	Canonical Corpus V1.1 - 27 PDF - 3.482 chunk
Pilot	20 câu hỏi - 27 nhóm evidence - 23 GT chunk duy nhất
Thực thi	Hoàn thành 20/20 - 89 phản hồi GPT-5 nano - 0 lỗi hạ tầng
Ngày báo cáo	2026-09-13

Phần I - Kết quả đánh giá pilot

Kết quả quan sát từ pilot kỹ thuật gồm 20 câu hỏi. Toàn bộ cảnh báo và giới hạn về tính hợp lệ được giữ nguyên.

Trạng thái

Thực thi: PASS (hoàn thành 20/20 câu hỏi). Đây là thử nghiệm kỹ thuật, chưa phải bộ benchmark khóa luận đã đồng băng. Benchmark sử dụng bước kiểm chứng nguồn có hỗ trợ của agent và hiện có **0/20 câu hỏi được con người kiểm chứng độc lập**. Vì vậy, validator chính thức nghiêm ngặt chủ động trả về lỗi theo thiết kế. Các kết quả dưới đây phải được ghi rõ là *tạm thời* cho đến khi hoàn tất `ground_truth_review.csv`.

- Corpus: Canonical Corpus V1.1, gồm 27 PDF và 3.482 chunk được lập chỉ mục.
- SHA-256 corpus: `fd2358332668de3dca8c099ff6a3dd0cf1d23b47c378f7c92835df4a08c34c02`.
- Bộ thử nghiệm: 20 câu hỏi, 27 nhóm evidence bắt buộc, 23 GT chunk duy nhất.
- Phân bố: 5 direct lookup, 5 paraphrase, 3 terminology mismatch, 4 multi-evidence và 3 cross-document.
- GT firewall lúc chạy: PASS. Đầu vào runtime chỉ chứa `id` và `query`.
- Mô hình yêu cầu: `gpt-5-nano`; cả 89 phản hồi đều được phân giải thành `gpt-5-nano-2025-08-07`; tất cả response ID đều tồn tại và duy nhất.
- Lỗi API/hạ tầng: 0.

Định nghĩa chỉ số

- `Recall@k` là tỷ lệ số GT chunk duy nhất được tìm thấy trong top-k, lấy trung bình macro.
- `MRR@10` sử dụng nghịch đảo thứ hạng của GT chunk đầu tiên.
- Evidence-group Coverage (EGC)`@k` là tỷ lệ nhóm evidence bắt buộc có ít nhất một chunk hợp lệ xuất hiện trong top-k.
- Complete Evidence chỉ đạt khi toàn bộ nhóm evidence của câu hỏi đều được bao phủ.

Mỗi nhóm evidence trong pilot hiện chỉ có một chunk được chấp nhận, nên `Recall@k` và `EGC@k` có cùng giá trị số. Hai chỉ số vẫn được cài đặt riêng vì trong tương lai một nhóm có thể có nhiều chunk thay thế hợp lệ.

Kết quả retrieval B0

Giai đoạn	R@1	R@3	R@5	R@10	MRR@10	EGC@10	Đủ evidence @10
BM25	0.525	0.800	0.850	0.875	0.746	0.875	16/20
Dense	0.500	0.625	0.775	0.850	0.672	0.850	16/20
Hybrid + RRF	0.525	0.825	0.825	0.875	0.742	0.875	16/20
Hybrid + RRF + reranker	0.575	0.825	0.825	0.825	0.767	0.825	15/20

Reranker cải thiện kết quả ở hạng 1 và MRR so với hybrid thô, nhưng đẩy evidence đầy đủ của một câu hỏi ra khỏi top-10 (từ 16 còn 15 câu). Đây là đánh đổi được đo trực tiếp, không phải căn cứ để tinh chỉnh trên chính bộ pilot này.

Ở giai đoạn B0 cuối, `R@10` của direct lookup là 1.000, terminology mismatch là 1.000, paraphrase là 0.800, cross-document là 0.667 và multi-evidence là 0.625. Chỉ 2/4 câu multi-evidence và 1/3 câu cross-document có đầy đủ evidence trong top-10.

Kết quả retrieval/evidence của S2G

Candidate pool và evidence cuối được báo cáo riêng. Iterative candidate pool chứa sáu chunk có thứ hạng reranker cao nhất ở mỗi vòng retrieval đã thực thi. Selected evidence chứa các parent chunk được sentence selector chấp nhận; answer citations là tập con được answer reasoner sử dụng.

Giai đoạn	R@1	R@3	R@5	R@10	MRR@10	EGC@10	Đủ evidence @10
Iterative candidate pool	0.625	0.750	0.800	0.800	0.777	0.800	14/20
S2G selected evidence	0.625	0.700	0.750	0.750	0.785	0.750	13/20
Answer citations	0.600	0.750	0.750	0.750	0.767	0.750	13/20

S2G không vượt B0 về retrieval top-10 trong pilot này. So với B0 hybrid+reranker, R@10 của candidate S2G giảm từ 0.825 xuống 0.800, còn R@10 của selected/cited evidence giảm xuống 0.750. MRR@10 của selected evidence cao hơn nhẹ (0.785 so với 0.767), cho thấy evidence tìm được có độ chính xác sớm tốt hơn nhưng độ bao phủ tổng thể yếu hơn.

Vấn đề chính là độ bao phủ multi-evidence. Ở giai đoạn selected evidence, R/EGC@10 chỉ đạt 0.250 và số câu đủ evidence là 0/4. Direct lookup và terminology mismatch đều đạt 1.000; paraphrase đạt 0.800; cross-document đạt 0.667.

Phân tích luồng evidence

- P007 và P015: GT không xuất hiện trong top-10 B0 lẫn candidate pool của S2G.
- P014 và P018-P019: chỉ một trong hai nhóm evidence bắt buộc được tìm thấy/trích dẫn.
- P016: cả hai GT chunk đều có trong iterative candidate pool nhưng không chunk nào được đưa vào selected evidence. Đây là mất mát tại selector/controller, không phải lỗi của retrieval giai đoạn đầu.
- P017: top-10 B0 chứa cả hai GT chunk, còn candidate pool giới hạn sáu chunk mỗi vòng của S2G chỉ chứa một. Việc kiểm tra cũng phát hiện khả năng ground truth bị mơ hồ giữa một quy định tổng quát và một quy định cụ thể.

Không tham số retrieval hoặc prompt nào được thay đổi sau khi quan sát các trường hợp này.

Đánh giá chất lượng câu trả lời có hỗ trợ của agent

Đánh giá này hữu ích cho việc chẩn đoán nhưng **không phải đánh giá độc lập của con người**. Tỷ lệ PASS dùng toàn bộ 20 câu hỏi làm mẫu số; REVIEW không được tính là PASS.

Tiêu chí	PASS	FAIL	REVIEW	PASS / 20
Tính đúng đắn	14	5	1	70%
Tính đầy đủ	13	6	1	65%
Trung thành với evidence	15	4	1	75%
Mức đầy đủ của trích dẫn	12	7	1	60%
Độ rõ ràng	18	2	0	90%

Mười trong 20 câu trả lời đạt đồng thời bốn tiêu chí cốt lõi: đúng đắn, đầy đủ, trung thành với evidence và trích dẫn đầy đủ. Vấn đề nổi bật là không trả lời đủ các vế của câu multi-evidence, chỉ trích dẫn một tài liệu/nhóm bắt buộc, hoặc trả lời từ một quy định lân cận có vẻ hợp lý nhưng không đúng evidence cần thiết. P013 diễn giải sai rằng chỉ cần có chứng chỉ MOS là được bỏ qua môn học; nguồn yêu cầu phải thi đánh giá và đạt ngưỡng. P015 sai đáng kể, P016 trả lời thiếu căn cứ và P019 bỏ sót phần đối tượng đại học. P017 giữ trạng thái REVIEW vì hai quy định nguồn có mức độ cụ thể khác nhau về thời điểm nộp hồ sơ.

Phiếu đánh giá con người chưa bị chỉnh sửa là file `answer_quality_review.csv` trong thư mục kết quả pilot.

Độ trễ, token và chi phí API

Độ trễ retrieval cục bộ của B0 (giây/câu hỏi)

Thành phần	Trung bình	Trung vị	P95	Lớn nhất
BM25	0.011	0.010	0.020	0.022
Dense	0.088	0.062	0.131	0.766
Reranker	0.999	0.956	1.215	1.913
Tổng	1.099	1.017	1.368	2.694

Chi phí API của B0 bằng 0 vì các mô hình retrieval chạy cục bộ. Con số này không bao gồm chi phí phần cứng, điện năng hoặc công sức kỹ thuật.

Tài nguyên S2G

- Độ trễ end-to-end: trung bình 22.978 giây, trung vị 21.666 giây, P95 41.059 giây, lớn nhất 45.716 giây.
- Độ trễ gọi provider: trung bình 20.895 giây/câu.
- Độ trễ retrieval qua các vòng lặp: trung bình 2.046 giây/câu.
- Số vòng retrieval: trung bình 1,30, trung vị 1, lớn nhất 3.
- Lý do dừng: 17 STOP_SUFFICIENT, 3 STOP_NO_NEW_EVIDENCE.
- Số lần gọi provider: tổng 89, trung bình 4,45/câu, gồm 43 judge, 26 sentence selector và 20 answer reasoner.
- Token: 143.847 input, 65.214 output, trong đó có 46.720 reasoning token; provider không báo cáo cached input token.
- Chi phí OpenAI API ước tính: **0,03327795 USD cho toàn bộ**, tương đương **0,00166390 USD/câu**.

Ước tính dùng lượng token được ghi nhận và giá GPT-5 nano tại ngày 2026-09-13: 0,05 USD/triệu input token, 0,005 USD/triệu cached input token và 0,40 USD/triệu output token. Chi phí này không bao gồm tính toán cục bộ và mạng.

Kết luận về tính hợp lệ và checkpoint tiếp theo

Phần mềm và quá trình thực thi đều đạt; bằng chứng cho thấy S2G đang hoạt động tốt với câu hỏi direct/terminology nhưng chưa đáng tin cậy cho câu hỏi multi-evidence. Kết quả phù hợp cho chẩn đoán kỹ thuật và báo cáo tiến độ, nhưng **chưa phù hợp để dùng làm kết luận cuối cùng của khóa luận** vì hai lý do:

1. benchmark chưa được con người kiểm chứng ground truth độc lập;
2. chất lượng câu trả lời được đánh giá với hỗ trợ của agent và P017 cho thấy ít nhất một điểm mơ hồ trong annotation.

Bước tiếp theo là kiểm tra toàn bộ dòng trong ground_truth_review.csv, xử lý P017 mà không nhìn vào bảng xếp hạng retrieval, rồi đóng băng benchmark. Sau đó cần chạy một thực nghiệm chính thức mới, không tinh chỉnh, và đánh giá độc lập chất lượng câu trả lời. Không được thay đổi tham số retrieval/controller dựa trên pilot này rồi dùng lại chính các câu hỏi đó như một tập kiểm tra không thiên lệch.

Phụ lục A - Quy trình đánh giá

Định nghĩa, ground-truth firewall, lệnh tái lập, yêu cầu kiểm tra của con người và giới hạn diễn giải.

Phạm vi và trạng thái

Quy trình này đo lường sản phẩm full-PDF hiện tại theo năm khía cạnh:

1. recall của retrieval;
2. thứ hạng nghịch đảo trung bình (MRR);
3. độ bao phủ nhóm evidence (EGC);
4. chất lượng câu trả lời được con người đánh giá;
5. độ trễ end-to-end và chi phí OpenAI API.

data/evaluation/s2g_pilot_v1/queries.json là bộ pilot gồm 20 câu hỏi và 27 nhóm evidence dựa trên Canonical Corpus V1.1. Trạng thái hiện tại là DRAFT_AGENT_VERIFIED_PENDING_HUMAN. Các điểm số thô có thể dùng để chẩn đoán kỹ thuật nhưng không được mô tả là kết quả của một nghiên cứu annotation độc lập bởi con người. Báo cáo khóa luận chính thức yêu cầu hoàn tất ground_truth_review.csv và chỉ đổi trạng thái từng câu thành human_verified sau khi kiểm tra.

Ground-truth firewall

File benchmark chứa nhãn evidence. File runtime chỉ chứa đúng hai trường id và query; loader từ chối mọi trường bổ sung. Vì vậy, quá trình chạy retrieval và S2G không thể nhìn thấy ground truth. Offline evaluator chỉ đọc nhãn evidence sau khi bảng xếp hạng/kết quả đã được hoàn tất.

CLI mặc định yêu cầu trạng thái human_verified. Cờ --allow-pending-human chỉ là lựa chọn tường minh để chạy phép đo kỹ thuật tạm thời.

Chỉ số retrieval

- Recall@k: số chunk ID liên quan duy nhất xuất hiện trong k kết quả đầu, chia cho toàn bộ chunk ID liên quan duy nhất của câu hỏi.
- MRR@10: nghịch đảo thứ hạng của chunk liên quan đầu tiên trong 10 kết quả đầu; bằng 0 nếu không tìm thấy.
- Evidence-group Coverage@k: số nhóm evidence bắt buộc được bao phủ trong k kết quả đầu, chia cho tổng số nhóm bắt buộc. Một nhóm được bao phủ nếu xuất hiện ít nhất một chunk ID được chấp nhận của nhóm.
- Complete-evidence@k: chỉ đúng khi toàn bộ nhóm bắt buộc được bao phủ.

Các chỉ số được báo cáo theo từng câu hỏi, trung bình macro và theo query type. Với S2G, báo cáo tách riêng iterative candidate pool, các chunk do reranker trình bày, parent chunk được sentence selector chọn và citation của câu trả lời. Các giai đoạn này không thể dùng thay thế cho nhau.

Chất lượng câu trả lời

Kiểm tra tự động chỉ bao phủ các hợp đồng có thể cưỡng chế: citation ID phải thuộc final evidence và câu trả lời có nội dung phải kèm citation. Chất lượng ngữ nghĩa được kiểm tra trong answer_quality_review.csv. Người đánh giá ghi TRUE/FALSE cho tính đúng đắn, đầy đủ, trung thành với evidence, mức đầy đủ của citation và độ rõ ràng, kèm ghi chú. Toàn bộ trường HUMAN để trống khi file được tạo. Báo cáo phải luôn có cả tử số/mẫu số và tỷ lệ phần trăm; không được âm thầm loại câu trả lời insufficient.

Độ trễ và chi phí

Trace retrieval ghi độ trễ của BM25, dense, fusion, reranker và tổng thời gian. Trace S2G ghi độ trễ từng lần retrieval, độ trễ gọi provider và độ trễ end-to-end. Báo cáo sử dụng trung bình, trung vị, P95 và giá trị lớn nhất theo câu hỏi.

Chi phí token dùng usage do Responses API ghi nhận gồm `input_tokens`, `cached input token` và `output_tokens`. Cấu hình lưu ngày quan sát giá và nguồn giá. Ước tính này không bao gồm chi phí máy cục bộ, điện năng và mạng; do đó phải được gọi là chi phí API ước tính, không phải tổng chi phí hệ thống.

Các lệnh tái lập

Sử dụng môi trường của dự án:

```
[bash]
conda run -n ml-env python -m src.evaluation.cli validate
conda run -n ml-env python -m src.evaluation.cli export-runtime \
  --output data/evaluation/s2g_pilot_v1/runtime_queries.json
conda run -n ml-env python -m src.evaluation.cli run-b0 \
  --runtime-queries data/evaluation/s2g_pilot_v1/runtime_queries.json \
  --output outputs/evaluation/s2g_pilot_v1/b0_rankings.json
conda run -n ml-env python -m src.evaluation.cli evaluate-b0 \
  --rankings outputs/evaluation/s2g_pilot_v1/b0_rankings.json \
  --output outputs/evaluation/s2g_pilot_v1/b0_metrics.json
conda run -n ml-env python -m src.evaluation.cli run-s2g \
  --runtime-queries data/evaluation/s2g_pilot_v1/runtime_queries.json \
  --output-root outputs/evaluation/s2g_pilot_v1/s2g_runtime
conda run -n ml-env python -m src.evaluation.cli evaluate-s2g \
  --runtime-root outputs/evaluation/s2g_pilot_v1/s2g_runtime \
  --output-root outputs/evaluation/s2g_pilot_v1
```

Cho đến khi hoàn tất kiểm chứng bởi con người, chỉ thêm `--allow-pending-human` vào các lệnh `validate`, `export` và `offline evaluation`. Lệnh thực thi chỉ đọc file runtime đã loại nhãn và không bao giờ tải benchmark.

Giới hạn diễn giải

Hai mươi câu hỏi được phân tầng chỉ là pilot, không phải ước lượng toàn diện cho mọi câu hỏi có thể có của sinh viên. Việc soạn câu hỏi, kiểm tra ground truth, hành vi mô hình, nhiễu OCR và sự mơ hồ về vòng đời tài liệu là các nguy cơ độc lập đối với tính hợp lệ. Không được tinh chỉnh prompt, cấu hình retrieval hoặc câu hỏi sau khi xem kết quả từng câu trong pilot rồi báo cáo trên chính tập đó như một kết quả không thiên lệch.

Nguồn nội dung: `docs/s2g-pilot-evaluation-results.md` và `docs/evaluation-protocol.md`. Bản tiếng Việt giữ nguyên số liệu và thuật ngữ kỹ thuật của hai tài liệu nguồn.